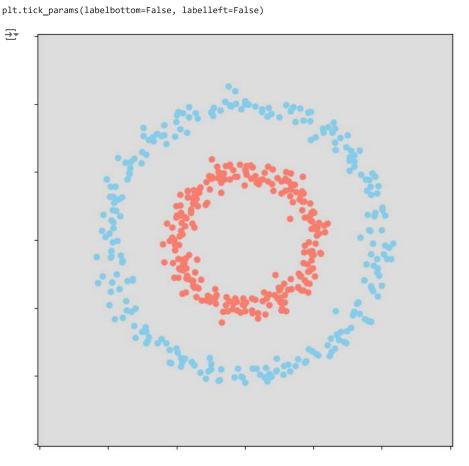
Sklearn

```
import numpy as np
import matplotlib.pyplot as plt
import scipy as sp
from sklearn.datasets import make_circles
#Creamos nuestros datos artificiales, donde buscaremos clasificar
# dos anillos concéntricos de datos
X, Y = make_circles(n_samples=500, noise=0.05, factor=0.5)
res=100
#Coordenadas del mapa de predición
_xo = np.linspace(-1.5, 1.5, res)
_x1 = np.linspace(-1.5, 1.5, res)
#Input con cada combo de coordenadas del mapa de predicción
_pX = np.array(np.meshgrid(_xo, _x1)).T.reshape(-1, 2)
# Objeto vacío a 0.5 del mapa de predicción
_pY = np.zeros((res, res)) +0.5
#Visualización del mapa de predicción
plt.figure(figsize=(8,8))
plt.pcolormesh(_xo, _x1, _pY, cmap="coolwarm", vmin=0, vmax=1)
#Visualización de la nube de datos
plt.scatter(X[Y==0, 0], X[Y==0, 1], c="skyblue")
\verb|plt.scatter(X[Y==1, 0], X[Y==1, 1], c="salmon")|\\
```





 $\hbox{\tt\#Import tensorflow as tf}$



```
import tensorflow.compat.v1 as tf
tf.disable_v2_behavior()
from matplotlib import animation
from IPython.core.display import display, HTML
# Definimos los puntos de entrada de la red, para la matriz X e Y
iX = tf.placeholder('float', shape=[None, X.shape[1]])
iY = tf.placeholder('float', shape=[None])
1r=0.01
                  #learning rate
nn=[2,16,8,1]
                  #número de neuronas por capa
# Capa 1
W1 = tf.Variable(tf.random_normal([nn[0], nn[1]]), name='Weights_1')
b1 = tf.Variable(tf.random_normal([nn[1]]), name='bias_1')
11 = tf.nn.relu(tf.add(tf.matmul(iX,W1), b1))
# Capa 2
W2 = tf.Variable(tf.random_normal([nn[1], nn[2]]), name='Weights_2')
b2 = tf.Variable(tf.random_normal([nn[2]]), name='bias_2')
12 = tf.nn.relu(tf.add(tf.matmul(l1,W2), b2))
W3 = tf.Variable(tf.random normal([nn[2], nn[3]]), name='Weights 3')
b3 = tf.Variable(tf.random_normal([nn[3]]), name='bias_3')
#Vector de predicciones de Y
pY = tf.nn.sigmoid(tf.add(tf.matmul(12,W3), b3))[:,0]
# Evaluacion de las predicciones
loss = tf.losses.mean_squared_error(pY,iY)
\#Definimos al optimizador de la red, par que minimice el error
optimizer = tf.train.GradientDescentOptimizer(learning rate=0.05).minimize(loss)
n_steps=1000
                      #Numero de ciclos de entrenamiento
iPY=[]
                      #Vector de predicciones. Aqui guardaremos la evolucion de las
                     #predicciones en cada ciclo de entrenamiento, para la animacion
with tf.Session() as sess:
  # Inicializamos todos los parametros de la red, las matrices W y b
    sess.run(tf.global_variables_initializer())
    # Iteramos n pases de entrenamiento
    for step in range(n_steps):
      # Evaluamos al optimizador, a la funci[on de coste y al tensr de salida pY
      # La evaluacion del optimizer producira el entrenamiento de la red
      _, _loss, pY = sess.run([optimizer, loss, pY], feed_dict={iX : X, iY : Y})
      # Cada 25 interacciones, imprimimos metricas
      if step % 25 == 0:
        # Calculo del accuracy
        acc = np.mean(np.round(_pY) == Y)
        # Impresion de metricas
        print('Step',step,'/',n_steps,'- Loss =', _loss, '-Acc =',acc)
        # Obtenemos predicciones para cada punto de nuestro mapa de predicciones _pY
        pY = sess.run(pY, feed dict={iX: pX}).reshape((res, res))
        \# Guardamos las predicciones en iPY para visualizar la animacion
        iPY.append(pY)
# Codigo Animacion
ims=[]
fig=plt.figure(figsize=(10,10))
print('--- Generando animacion ---')
for fr in range(len(iPY)):
  im =plt.pcolormesh(_x0,x1,iPY[fr],cmap='coolwarm',animated=True)
  # Visualizacion de la nube de datos
  \verb"plt.scatter"(X[Y==0, 0], X[Y==0, 1], c="skyblue")
  plt.scatter(X[Y==1, 0], X[Y==1, 1], c="salmon")
  # plt.title("Resultado Clasificacion")
  plt.tick_params(labelbottom=False, labelleft=False)
  ims.append([im])
ani=animation.ArtistAnimation(fig,ims,interval=50,blit=True,repeat_delay=1000)
HTML(ani.to_html5_video())
```



```
ValueError
                                    Traceback (most recent call last)
    <ipython-input-16-5767333ae462> in <cell line: 41>()
             if step % 25 == 0:
       50
       51
                # Calculo del accuracy
                acc = np.mean(np.round(_pY) == Y)
       53
                # Impresion de metricas
       54
                print('Step',step,'/',n_steps,'- Loss =', _loss, '-Acc =',acc)
    ValueError: operands could not be broadcast together with shapes (100,100) (500,)
Keras
import tensorflow as tf
import tensorflow.keras as kr
lr=0.01
              #learning rate
nn=[2,16,8,1]
              #número de neuronas por capa
# Creamos el objeto que contendrá a nuestra red neuronal como secuencia de capas
model = kr.Sequential()
# Agregamos una capa de entrada, capa 1
11=model.add(keras.layers.Dense(nn[1],activation='relu'))
# Agregamos una capa oculta, capa 2
12=model.add(keras.layers.Dense(nn[2],activation='relu'))
# Agregamos una capa de salida, capa 3
13=model.add(keras.layers.Dense(nn[3],activation='sigmoid'))
# Compilamos el modelo, definiendo la función de coste y el optimizador
model.compile(loss='mse', optimizer=kr.optimizers.SGD(lr=0.05), metrics=['acc'])
# Y entrenamos al modelo. los callbacks
model.fit(X,Y, epochs=100)
环 WARNING:absl:`lr` is deprecated in Keras optimizer, please use `learning_rate` or use the legacy optimizer, e.g.,tf.keras.optimizers.l
    Epoch 1/100
    16/16 [==============] - 1s 3ms/step - loss: 0.2367 - acc: 0.5000
    Epoch 2/100
    16/16 [============ ] - 0s 3ms/step - loss: 0.2363 - acc: 0.5000
    Epoch 3/100
    16/16 [==============] - 0s 3ms/step - loss: 0.2360 - acc: 0.5000
    Epoch 4/100
    16/16 [============== ] - 0s 3ms/step - loss: 0.2357 - acc: 0.5000
    Epoch 5/100
    Epoch 6/100
    16/16 [============ ] - 0s 2ms/step - loss: 0.2351 - acc: 0.5000
    Epoch 7/100
    16/16 [============ ] - 0s 3ms/step - loss: 0.2348 - acc: 0.5000
    Epoch 8/100
                 16/16 [======
    Epoch 9/100
    Epoch 10/100
    16/16 [============= ] - 0s 4ms/step - loss: 0.2339 - acc: 0.5020
    Epoch 11/100
    16/16 [======
                Epoch 12/100
    16/16 [============ ] - 0s 3ms/step - loss: 0.2333 - acc: 0.5160
    Epoch 13/100
    16/16 [======
                Epoch 14/100
    16/16 [============= ] - 0s 3ms/step - loss: 0.2327 - acc: 0.5340
    Epoch 15/100
    16/16 [=====
                    ========] - 0s 3ms/step - loss: 0.2324 - acc: 0.5520
    Epoch 16/100
    16/16 [============= ] - 0s 3ms/step - loss: 0.2321 - acc: 0.5660
    Epoch 17/100
    16/16 [=============] - 0s 3ms/step - loss: 0.2318 - acc: 0.5800
    Epoch 18/100
    16/16 [=====
                Epoch 19/100
    Epoch 20/100
    16/16 [===============] - 0s 3ms/step - loss: 0.2309 - acc: 0.6040
```

```
Epoch 21/100
16/16 [============] - 0s 3ms/step - loss: 0.2306 - acc: 0.6240
Epoch 22/100
Epoch 23/100
16/16 [=============] - Os 3ms/step - loss: 0.2300 - acc: 0.6380
Epoch 24/100
16/16 [=============] - 0s 4ms/step - loss: 0.2297 - acc: 0.6500
Epoch 25/100
Epoch 26/100
Epoch 27/100
Epoch 28/100
```

